2026年度「機械学習応用」
中古マンション価格予測 中間報告
Di molt

2026/10/16

南條 佑太、大久保 翔、藤瀬 太翼、小林 麟太郎

役割分担（人とAIの分担も含めて）

- **人の分担**
  - 全員：各自のノートブックで EDA を行い、実験ごとに Issue を立てて PR を出した
  - 藤瀬 太翼：実験の土台（構成・時系列 CV・AI への指示ファイル）と開発の手順を整え、損失関数・目的変数の設計などの実験と、PR のレビューを担当した
  - 南條 佑太：isotonic 較正を作り、CV と LB のずれの分析など、PR・Issue での議論とレビューを担った
  - 大久保 翔：最初のベースラインを作り、目的変数の設計の実験を今の土台に移し替えて再実装した
  - 小林 麟太郎：目的変数を総額から㎡単価に変え、間取りを部屋数などに分解する特徴量を試した
- **AIの分担**
  - リポジトリの構成と関数の切り分けの案、前処理・特徴量・学習のコード
  - Issue にした実験の実行と、結果をまとめた PR の作成、PR の妥当性のレビュー
- **AIの出力の確認**
  - 構成とコード：AI と議論し、出力されたコードを VS Code で読みながら直し、ruff の整形と静的チェックの後も、読みにくい箇所や名前は自分で直した
  - 変更の単位：分析の工程ごとにファイルを分け、1 回の PR は 1 つの工程の修正と検証に限って、人が検証結果と実装コードを把握できる範囲に抑えた
  - 検証：AI が出した結果や指摘はそのまま信じず、全員が同じ 3 fold の時系列 CV で測り、提出した LB と連動するかも確かめてから採否を決めた
- **使ったAIツール**
  - Claude Code（藤瀬・南條）、Antigravity CLI（大久保・小林。無料プランで使える範囲が広いため）

試した手法やモデルとその結果

- 評価：RMSLE（小さいほど良い）。過去で学習し、直後の3四半期を当てる 3 fold の時系列 CV の平均を CV スコアとする
- 表の値：上の行までに採用した変更を積み上げた値
- 今の最高は LB 0.19709。上位チームは 0.19408 で、まだ 0.003 差がある
- CV と LB のずれ（isotonic 較正）：較正表は学習期間の直近 3 四半期で作るため、値段が上がり続ける test では範囲外の予測が頭打ちになり、低く出たと考える。目的変数の設計を見直した後は CV でも悪化したので、時期によるずれを較正がまとめて直していた分が test に合わなかった可能性もある

試したこと（手法・モデル・特徴量）	手元の検証スコア	Publicスコア	メモ（採用したか など）
LightGBM のベースライン	0.20674	0.20542	基準
cat_smooth（カテゴリの扱い）と learning_rate（学習率）の調整	0.20360	0.20222	採用。CV と LB が同じ幅で改善
損失関数を二乗誤差から Huber 損失に変更	0.20004	0.19914	採用。3 fold すべてで改善
isotonic 較正で予測を後から補正	0.19727	0.20059	不採用。CV は良いが LB で悪化した
目的変数を㎡単価にする（予測に面積を掛けて戻す）	0.19845	—	採用
目的変数の設計を見直す	0.19664	0.19709	採用予定（レビュー中）。LB が最高
効かなかったもの：場所の特徴量・容積率の補完など（Huber 時点）、外れ値の重み・間取りの分解（最新の土台の上）	差 0.0004 以内	—	不採用

AIの提案：採用したもの・却下したもの

リポジトリ設計とコードは AI の案を議論して直してから採用し、実験の案とレビューの指摘は CV とデータで確かめて採否を決めた

AIの提案	採用 / 却下	理由（どう確かめたか）
リポジトリ設計・コード：実験ごとに記録用のフォルダを作り、工程番号つきのファイルに分ける。学習と予測を 1 つの関数で行う	修正して採用	議論して、実験の記録は PR に一本化し、ファイルは工程ごと、関数は CV 用と本番用に分けた。分ける前後で CV が完全に一致することを確かめた
実験の案：件数の少ないカテゴリでも木が分岐できるよう、パラメータを下げる	却下	両方の向きに値を変えて時系列 CV で比べ、CV が変わらず、逆向き（件数の少ないカテゴリを全体の平均に寄せる）のほうが効いた
PR のレビュー：較正の移植で見つけた不具合 2 件	採用	直したあとも CV が変わらないことを確かめた
PR のレビュー：分位点の取り方と、欠けた値の埋め方がおかしい	却下	グループごとの件数を 2 通りの分け方で数え比べ、前者はわざと（件数をそろえるため）と分かった。後者は全 fold で欠けた値を数え、起きないと分かった
実装：理由の書かれていない決め打ちの値（期間の区切り・グループの数・くり返しの回数）	修正して採用	区切りの年やくり返しの回数を何通りか変えて、結果がほとんど変わらないことを確かめたうえで、定数にして理由を書くよう直した。影響の大きい値は今後の改善の対象にした

共同開発方法

- **リポジトリの構成**
  - main.py は工程を順に呼ぶだけにし、前処理・特徴量・目的変数・モデルなど、工程ごとにファイルを 1 つにした
  - 特徴量は MAKERS、モデルは MODELS に 1 行足すだけで試せる。別々の実験を最新の土台に積み直しても衝突しなかった
- **実験の進め方（GitHub）**
  - 1 つの実験を Issue → ブランチ → PR で進め、PR に fold ごとの CV・比べた main のコミット・Public LB を書く
  - 効かなかった実験も「不採用」ラベルで閉じて残し、同じ実験を二度試さない
  - レビューは藤瀬が中心に行い、AI のレビューの指摘もデータで確かめてから直してマージする
- **AIへの指示ファイル（CLAUDE.md・AGENTS.md）**
  - テスト期間（2025年第3四半期以降）の取引データを取得・参照しない規約と、検証方法を合意なしに変えないこと
  - 価格を使う処理は fold ごとに作ること、型ヒント・docstring・名前の決まり
- **グループ内の情報共有**
  - Discord で PR を報告して全員が確認し、submission チャンネルで日ごとの提出担当を割り当てる
  - 10/11 に全員で MTG を開き、土台の構成と担当を決めた

ここまでの進め方で良かった点・悪かった点

- **良かった点**
  - チームの土台の上では全員が同じ時系列 CV で比べたので、施策の良し悪しを同じ基準で判断できた
  - CV と LB のずれを提出で切り分け、isotonic 較正が test で効いていないと分かって外せた
  - AI のレビューの指摘も、設計の元にした EDA の値も、データで確かめてから採否を決めた
  - 不採用の実験も PR に残し、同じ実験を二度試さずに済んだ
- **悪かった点**
  - 土台の整備に時間がかかり、実験の着手が遅れた
  - isotonic 較正を CV だけで「採用予定」にし、LB で悪化すると分かるまで時間がかかった
  - EDA で決めた値の一部に根拠がなかった（結果への影響はほぼなし）
- **最終報告までに変えること**
  - 提出の担当者が自分で main を動かして提出し、コードの理解とコミットが1人に偏らないようにする
  - 効いた特徴量を積み上げ、モデルを混ぜる